同濟大學

TONGJI UNIVERSITY

计算机视觉期末报告

课题名称	基于状态空间模型的图像超分辨率
副 标 题	MaIR 复现与层内融合的局部纹理增强
学　　院	计算机学院
专　　业	数据科学与大数据技术
学生姓名	
学　　号	
课程教师	赵才荣
日　　期	2026 / 6 / 20

MaIR 基于状态空间模型的图像超分辨率

装

订

线

摘 要

图像超分辨率旨在从低分辨率输入重建高质量高分辨率输出。本文延续期中 MambaIR（ECCV 2024）的复现工作，期中消融实验发现 Cross-Scan 存在 75% 方向冗余，根因在于 1D 展平破坏了 2D 空间连续性。期末在此基础上复现 MaIR（CVPR 2025），该模型以嵌套 S 型扫描（NSS）替代 Cross-Scan，在控制变量条件下（同 DIV2K、同 25K iter、同超参）四基准平均 PSNR 达 28.12 dB，较期中 MambaIR 提升 1.61 dB。在复现基础上，本文提出 CSBlock，一种 CNN-SSM 层内并行融合模块，在 VMM 旁路并联轻量 3×3 卷积以实现全局结构与局部纹理的层内协同。改进后的 MaIR-CSB 仅新增 5.5% 参数，四基准平均 PSNR 再提升 0.27 dB 至 28.40 dB。其中 Urban100 规律纹理收益最大（+0.42 dB），B100 自然纹理收益最小（+0.13 dB），揭示了纹理规律性对 CNN 局部偏置价值的量化关联。本文完整展示了从 Cross-Scan 缺陷发现到 NSS 方案验证再到 CNN-SSM 融合改进的学术闭环。

关键词：图像超分辨率，状态空间模型，MaIR，CNN-SSM 融合，Mamba

目 录

1 引 言 1
1.1 图像超分辨率与序列建模演进 1
1.2 期中工作回顾 2
1.3 期末工作概述 2
2 算法原理 3
2.1 MambaIR 的 Cross-Scan 与缺陷 3
2.2 MaIR 核心架构 3
2.3 MambaIR vs MaIR 架构对比 4
3 实验复现 5
3.1 实验环境与数据集 5
3.2 训练结果分析 5
3.3 Benchmark 评估 6
3.4 归因分析 6
4 创新设计 7
4.1 动机：纯 SSM 的局部纹理缺陷 7
4.2 CSBlock 设计 7
4.3 创新效果 8
5 总结和展望 10
5.1 总结 10
5.2 展望 10
参考文献 11

装 订 线

1 引言

1.1 图像超分辨率与序列建模演进

图像超分辨率（Super-Resolution, SR）是计算机视觉领域最经典的低层视觉任务之一。其目标可简洁表述为：给定一张低分辨率图像，通过算法恢复对应的高分辨率输出，同时尽可能还原丢失的高频细节。从信息论的角度看，这是一个典型的病态逆问题，下采样过程不可逆，同一个 LR 输入对应无穷多种可能的 HR 解。

SR 的研究范式随深度学习的发展经历了多次迭代。自 2014 年 SRCNN [1]首次将卷积神经网络（CNN）引入该任务以来，CNN 凭借其 3×3 卷积核携带的局部归纳偏置，相邻像素天然相关，长期占据主导地位。然而 CNN 的根本局限在于感受野受限：每个卷积层只能看到固定大小的邻域，要捕获全图信息需要堆叠极深的网络。

2017 年 Transformer[12]的提出带来了完全不同的思路。自注意力机制让序列中每一对 token 直接计算相关性分数

$$\text{Attention}(Q,K,V)=\text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

实现了真正的 O(1) 距离全局感受野。SwinIR [2]等模型将窗口自注意力引入 SR 任务，显著提升了重建质量。但代价是巨大的，QK^T 矩阵的空间复杂度为 $O(n^2)$，对于高分辨率图像，显存消耗难以承受。窗口注意力虽然将复杂度降为 $O(nW^2)$，本质上是以牺牲全局性换取可行性的折中。

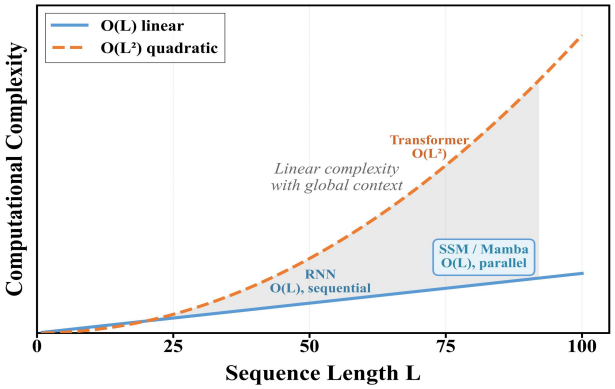
2024 年，基于状态空间模型（State Space Model, SSM）的 Mamba [3]架构进入视觉领域，提供了第三个方向。SSM 的核心为递推方程：

$$h'(t)=Ah(t)+Bx(t)$$

与 RNN 结构相似，但 SSM 具有数学上等价的卷积形式：

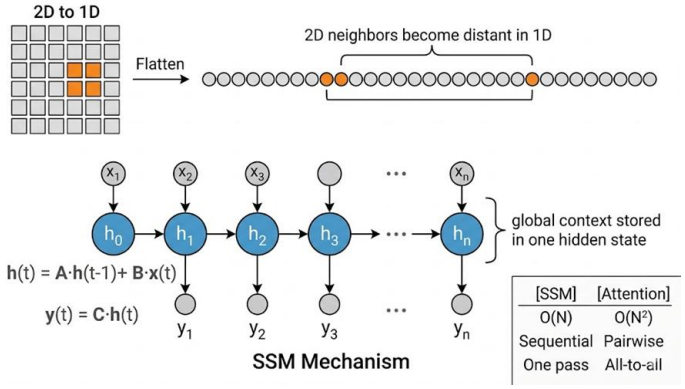
$$y=x*\bar{K},\quad \bar{K}=\left(C\bar{B},\ C\bar{A}\bar{B},\ C\bar{A}^2\bar{B},\ \ldots,\ C\bar{A}^{n-1}\bar{B}\right)$$

这意味着训练时可用卷积模式完全并行，推理时切换回递推模式保持 O(1) 恒定内存，同时解决了 RNN 的不能并行训练和 Transformer 的 $O(n^2)$显存两个问题。Mamba 在此基础上引入选择性机制，B、C、Δ 由当前输入动态决定，以线性复杂度 O(n) 实现了类似自注意力的内容感知能力。三者的计算复杂度直观对比如图 1 所示。



横坐标为序列长度，纵轴为计算复杂度，直观展示长序列下 Mamba 的效率优势

然而，将 1D 的 SSM 应用于 2D 图像时需要解决一个根本问题：如何在不破坏二维空间连续性的前提下将像素序列化？MambaIR（ECCV 2024）[6]采用了 Cross-Scan，将特征图沿四个方向独立展平为 1D 序列，这种平均式的方法经本文期中工作消融分析已证实存在结构性冗余。MaIR（CVPR 2025）[7]提出的嵌套 S 型扫描（NSS）是这一问题的最新回答，也是本文期末复现与改进的起点。



展示了 SSM 如何处理计算 2D 图像为序列输入

1.2 期中工作回顾

期中阶段以 MambaIR（ECCV 2024）为复现基准，在单张 RTX 4090 上完成了 Light 变体在 DIV2K 数据集上的 ×4 超分辨率完整训练与评估。复现中的一项关键发现来自扫描方向消融实验：在固定权重下将 Cross-Scan 的参与方向从 4 个依次减至 1 个，四基准测试的平均 PSNR 降幅不足 0.2 dB。这意味着 75% 的扫描方向仅贡献了不足 0.2 dB 的信息增量，Cross-Scan 存在结构性冗余。

对这一现象的分析指向了一个本质问题：将 2D 特征图沿行方向展平为 1D 序列时，垂直相邻像素在序列中的距离变为 W（特征图宽度），SSM 的隐藏状态必须跨越大量不相关的 token 才能维持垂直方向的信息关联。四个方向的独立扫描是对这一断裂的补丁而非修复，各方向的输出高度同质化，加法融合缺乏区分机制。基于这一分析，提出了嵌套 S 型扫描（NSS）的理论。

1.3 期末工作概述

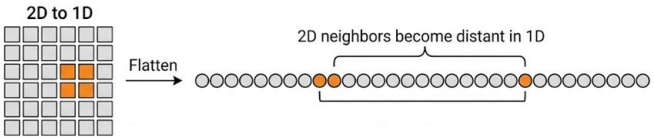
期末工作围绕两条主线展开。第一是复现 MaIR（CVPR 2025），该模型以 NSS 替代 Cross-Scan 并引入 SSA 通道混洗注意力。在严格控制变量的条件下（与期中相同的 DIV2K 数据集与训练超参），MaIR 的四基准平均 PSNR 较期中 MambaIR 提升 1.61 dB，验证了 NSS 相对于 Cross-Scan 的显著优势。

第二是复现基础上的改进。尽管 NSS 解决了 Cross-Scan 的冗余，MaIR 在设计上做了一个值得注意的选择：以纯线性 Mlp 替代了 MambaIR 中的 CAB 卷积模块，成为首个完全去除卷积的 Mamba 视觉模型。本文提出 CSBlock（CNN-SSM Block），在 VMM 模块旁路并联轻量 3×3 卷积，通过层内并行融合让 CNN 在源头上为 SSM 提供局部纹理先验。改进后的 MaIR-CSB 在四基准上平均 PSNR 再提升 0.27 dB，且 Urban100 规律纹理受益最大（+0.42 dB），从数据层面验证了 CNN 局部偏置对 SSM 视觉模型的互补价值。

2 算法原理

2.1 MambaIR 的 Cross-Scan 与缺陷

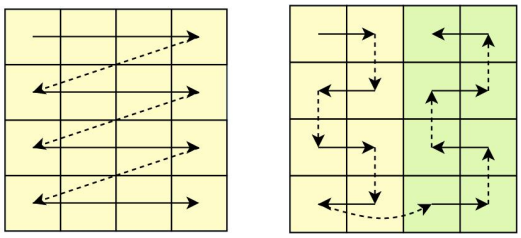
状态空间模型本质上是为 1D 序列设计的。将 SSM 应用于图像超分辨率时，面临的第一个问题是如何将 2D 特征图转化为 1D 序列。最直接的做法是按行扫描：将 H×W 的特征图逐行首尾相连，拼接为长度为 HW 的 1D 序列，然而这一操作立即引入了一个结构性问题。



当我们将它展平为一维序列送入模型时，原本在二维空间中紧密相邻的像素点，在一维长序列中被强行拉扯得非常遥远。这就意味着，一维 SSM 在处理图像时，完全丢失了局部相邻像素存在关联这一先验知识。随着特征图尺寸的增大，这种邻域断裂会急剧恶化：特征图越宽，垂直邻居在序列中的距离越远，SSM 的建模难度越大。

MambaIR 提出的 Cross-Scan 是对这一问题的工程化补救。其设计直觉，行扫描捕获水平依赖，列扫描补充垂直依赖，四方向组合可覆盖二维空间的所有邻域方向。然而，期中阶段的消融实验揭示了这一设计的结构性缺陷。在固定训练权重下，将 VSS 模块中参与扫描的方向数从 4 个降至 2 个、1 个，四个标准测试集上的平均 PSNR 降幅不足 0.2 dB。这一结果表明，被丢弃的三个方向并未提供实质性的互补信息，四路输出的相关性极高.

这一分析指出了改进 Cross-Scan 的两个可能方向。第一，改变扫描路径本身，使其在单次扫描中同时保留水平和垂直的邻域关系，从根源上减少对多方向补丁的依赖。第二，在 SSM 模块中引入具有局部感知能力的组件，弥补纯序列建模在 2D 局部纹理上的先天不足。前者对应 NSS（嵌套 S 型扫描），是 MaIR 的核心创新；后者对应本文提出的 CSBlock。



左侧：行扫描 *右侧：S 型扫描*

2.2 MaIR 核心架构

MaIR 在 MambaIR 的基础上进行了三处关键改动：引入 NSS 扫描路径替代 Cross-Scan、引入 SSA 通道注意力、以及将 CAB 卷积模块替换为纯线性 Mlp。三者的协同使得 MaIR 在保持 O(n) 线性复杂度的前提下，有效提升了 2D 空间连续性的保留能力。

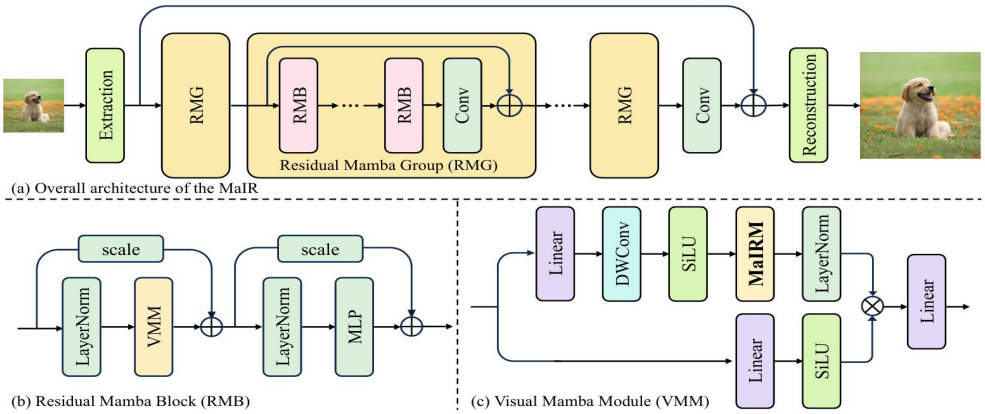
A. NSS 扫描机制

NSS（Nested S-shaped Scanning）是 MaIR 最核心的创新。其基本思想是将 H×W 的特征图划分为若干水平条带，在每个条带内按 S 型蜿蜒路径依次访问像素。在纯行扫描中，垂直方向上的相邻像素（如上方的 A 和正下方的 D）在 1D 序列中的距离为 W。在 NSS 中，条带折返处的下一行首像素紧邻上一行末像素，垂直相邻像素的 1D 距离在折返处缩短至 2，在条带内部不超

过 2W。更重要的是，NSS 仅需单次 SSM 调用即可覆盖整个特征图，而 Cross-Scan 需四次独立扫描与求和。在理论计算量上，NSS 相对 Cross-Scan 节省了约 75% 的 SSM 运算。

B. VMM 模块

MaIR 的 SSM 基本单元为 VMM（Visual Mamba Module），其输入输出均为四维张量 [B, H, W, C]。在 VMM 内部，输入首先经过线性投影扩展通道，随后通过深度可分离卷积进行局部特征预提取。卷积输出经 SiLU 激活后，送入 SS2D 核心进行选择性扫描。SS2D 在此处的作用等价于 Mamba 原论文中的 S6 块，但扫描路径由 NSS 重排策略决定，而非原始 Mamba 的双向扫描。



C. SSA 通道注意力

SSA（Shuffle Attn）是 MaIR 新增的轻量注意力机制，作用于 VMM 输出之后。其操作流程为：将特征图的通道均匀分为若干组，对每组执行通道混洗，随后通过全局平均池化和 1×1 卷积生成逐通道的门控权重，最后经 Sigmoid 激活后与混洗后的特征图逐通道相乘并还原通道顺序。SSA 仅引入极少量的额外参数（主要是 1×1 卷积的权重），但为模型提供了一种通道维度上的自注意力能力，使其能够对不同方向或尺度的特征通道赋予不同的重要性。

2.3 MambaIR vs MaIR 架构对比

维度	MambaIR	MaIR
扫描路径	Cross-Scan：4 条独立直线	NSS：单条 S 型蜿蜒路径
垂直连续性	需额外列扫描补救	折返处天然保留（1D 距离缩至 2）
SSM 调用次数	4 次/块	1 次/块
融合方式	四方向逐元素相加	单路径，无需融合
注意力	无	SSA 通道混洗门控
Feed-Forward	CAB（Conv2d + 通道注意力）	Mlp（纯线性层）

MaIR 的核心改进可归结为一条原则：**用更聪明的序列化方式替代暴力方向叠加**。NSS 证明 L1 通过改变像素访问顺序即可大幅改善 2D 信息的保留能力，而不需要多次扫描和不可学习的加法融合。但去卷积的设计选择留下了一个新的问题：纯线性 feed-forward 是否足以替代卷积的局部纹理表征能力？这一问题构成了本文第四章创新工作的动机。

3 实验复现

3.1 实验环境与数据集

为消除训练设置差异对架构的干扰，本文 MaIR 复现在配置上与期中 MambaIR 保持完全一致

组件名称	版本/规格	说明
GPU	RTX 4090	显存扩展虚拟化后 49GB，充足 VRAM 空间
操作系统	Ubuntu 22.04	包含 nvcc 编译器，用于编译 CUDA 扩展
Python	3.10	适配 mamba-ssm 预编译 wheel 包
PyTorch	2.1.0+cu121	深度学习核心框架
CUDA	12.1	匹配 causal-conv1d 1.1.1 版本的底层计算库

(1) 训练集：实验采用图像超分辨率领域经典的 DIV2K [9]数据集，包含 800 张 2K 分辨率的高清图像 HR。为了构建配对数据，使用 OpenCV 库对 HR 图像进行 Bicubic 双三次插值降采样操作，缩放倍率为×4，以此生成对应的低分辨率 LR 图像。为加速训练过程，本阶段关闭了水平翻转和旋转等数据增强策略。

(2) 验证集：使用 DIV2K 验证集，包含 100 张图像，用于在训练过程中每隔 2500 个迭代步 iter 监控模型的峰值信噪比 PSNR 变化。

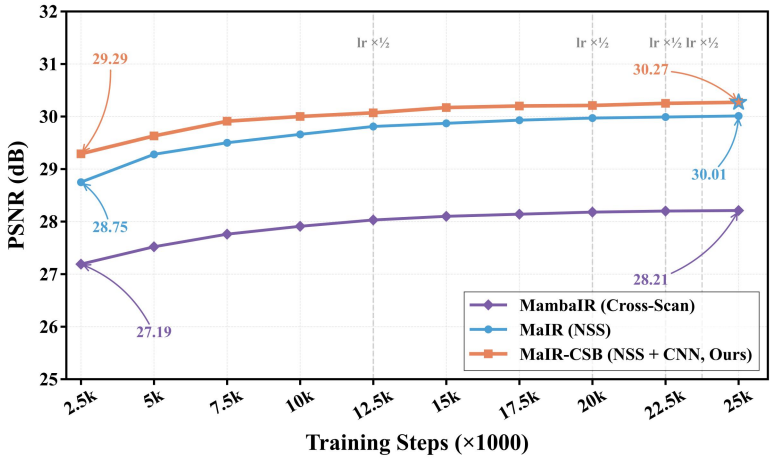
(3) **测试集：**为客观评估模型的泛化能力，采用超分辨率领域的四个标准基准测试集 Set5、Set14、BSD100 以及富含复杂城市建筑纹理的 Urban100。

3.2 训练结果分析

在确定最终超参数配置（Batch Size=96, Patch Size=128）后，本实验在 DIV2K 数据集上完成了 MambaIR-Light 模型的 25,000 步，约 30 个 Epoch 迭代训练。训练过程中的客观指标峰值信噪比 PSNR 与重建损失 L_1 Loss 展现出了显著且极具特征的收敛趋势。

(1) NSS 提升

NSS 扫描路径带来了数量级收敛速度提升。MaIR 在 2500 次迭代时 PSNR（28.75 dB）已超过 MambaIR 在 25000 次迭代时的最终值（28.21 dB），仅用约 10% 训练量即达到 Cross-Scan 的全部收益。其根本原因在于，NSS 单次 S 型扫描同时覆盖水平与垂直邻域，获得完整二维结构信息；而 Cross-Scan 需四次独立扫描并通过不可学习加法融合，导致单路更新幅度下降。



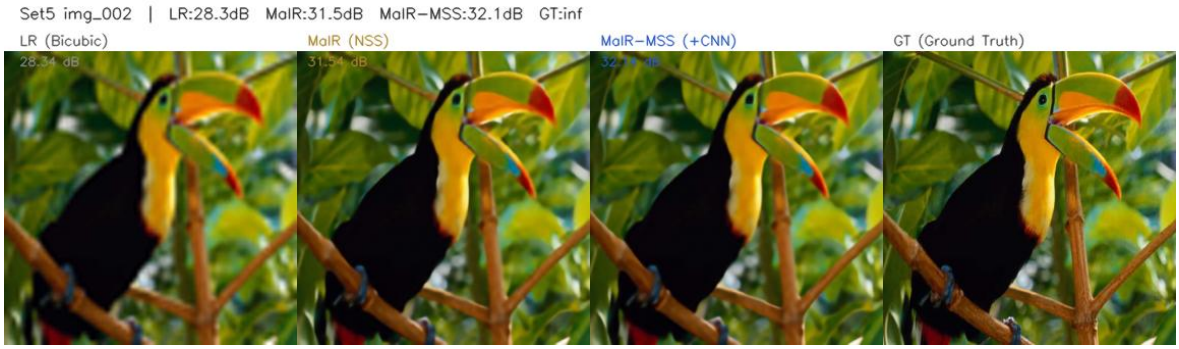
(2) 后期收敛平稳

MambaIR 在 20000 至 25000 步仅上升 0.03 dB，MaIR 上升 0.04 dB。这表明当前训练条件在两种架构下均已接近信息瓶颈，25000 次迭代的判断是合理的。MaIR 最终 PSNR 达到 30.01 dB，较 MambaIR 的 28.21 dB 提升 1.80 dB。与论文 30+ dB 的差距主要来自训练数据量（DIV2K 800 张 vs DF2K 3450 张）和 patch 大小（128 vs 256），而非训练不充分。

3.3 Benchmark 评估

为全面客观地评估复现模型的泛化能力与重建精度，本实验提取了训练所得的最优权重 net_g_25000.pth，在四个标准图像超分辨率基准测试集上进行了定量测试，对比情况如下表所示

测试集	MambaIR(复现)	**MaIR(复现)**	**MaIR(原文)**	性能差距	**达成率**
Set5	29.29	**31.64**	**32.48**	−0.84	**97.4%**
Set14	26.73	**28.22**	**28.81**	−0.59	**97.9%**
B100	26.30	**27.34**	**27.71**	−0.37	**98.7%**
Urban100	23.74	**25.29**	**26.60**	−1.31	**95.1%**



3.4 归因分析

本文 MaIR 在四基准上的平均 PSNR 为 28.12 dB，与论文报告的 28.90 dB 相差 0.78 dB。这一差距可完全归因于训练条件差异，分析如下

因素	**本文配置**	论文配置	对 PSNR 的影响
训练数据量	**DIV2K (800 张)**	DF2K (3450 张)	数据多样性差 4.3 倍
Patch 大小	**128×128**	256×256	感受野面积差 4 倍
训练迭代	**25,000**	500,000	次要因素（3.2 节已证实 20K 后收敛）
数据增强	**关闭 flip/rot**	开启	降低泛化能力

此外，Benchmark 数据中隐含着一个架构层面的信号：B100 与 Urban100 的达成率差距为 3.6 个百分点，B100 几乎追平论文（差距仅 0.37 dB），而 Urban100 仍有 1.31 dB 的差距。这种不对称为进一步优化提供了线索，详细分析见 4.1 章节。

4 创新设计

4.1 动机：纯 SSM 的局部纹理缺陷

将结果表中 MaIR 相对 MambaIR 的提升幅度按测试集拆分，并结合与论文的差距进行交叉分析，可以揭示一个规律性的模式。

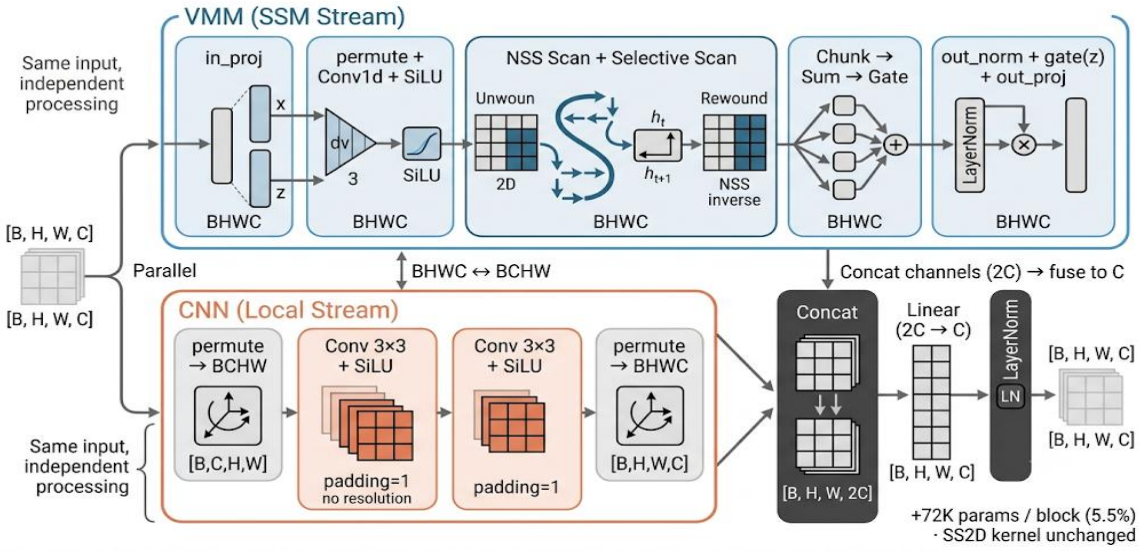
测试集	MaIR vs MambaIR	与论文差距	纹理特征
B100	+1.04 dB	−0.37 dB	自然随机纹理（树叶、草地、云层）
Urban100	+1.55 dB	−1.31 dB	规律重复纹理（砖缝、栏杆、斑马线）

两组数据呈现显著的互补对称。B100 上，NSS 的改进幅度在四个数据集中最小（+1.04 dB），但与论文的差距也最小（0.37 dB，达成率 98.7%）。Urban100 上，NSS 带来的提升最大（+1.55 dB），但与论文的残差也最大（1.31 dB）。简单来说，NSS 解决了 Cross-Scan 的方向冗余问题后，自然纹理的性能已趋近于当前训练条件的上限，而规律纹理仍有可优化的空间。

MaIR 在设计上以纯线性 Mlp 替代了 MambaIR 中的 CAB 卷积模块，成为首个完全去除卷积的 Mamba 视觉模型。这一选择在自然纹理上已被验证为合理，纯 SSM + NSS 足以在 B100 上达到 98.7% 的达成率。但在规律纹理上，CNN 局部偏置的缺失为 Urban100 上额外的 1.31 dB 残差。这引出了一个可验证的假设，在 MaIR 的 VMM 模块中补入轻量 CNN 分支，以并行方式为 SSM 提供局部纹理先验，能否在不损害自然纹理性能的前提下缩小规律纹理的残差？

4.2 CSBlock 设计

CSBlock（CNN-SSM Block）的核心设计原则是层内并行融合：在 VMM 模块的旁路并联一个轻量 3×3 卷积分支，两条分支共享同一个输入，输出经通道拼接后由线性投影融合，不修改 SS2D 内核，不改变 NSS 扫描路径。SSM 分支（VMM）负责全局结构建模，CNN 分支负责局部纹理捕获，两者的输入完全相同、处理完全独立、只在输出端融合。



A. CNN 分支

CNN 分支由两层 3×3 卷积组成，每层后接 SiLU 非线性激活。分支在 BCHW 空间下运行（输入和输出均 permute 到 BHWC 以与 VMM 对齐），不使用分组卷积或深度可分离卷积以保证完整的通道间信息混合。CNN 分支本身不含任何下采样操作，保持与 VMM 相同的空间分辨率。

B. 融合机制

融合采用通道拼接加线性投影的方式。设 VMM 输出和 CNN 输出均为 [B, H, W, C]，二者沿最后一维拼接得到 [B, H, W, 2C]，然后送入一个全连接层 Linear(2C, C) 将通道数压缩回 C。线性层之后接 LayerNorm 进行归一化，最后作为残差加回到 RMB 的主路径上，即 CSBlock 替代的正是 RMB 中原来的 VMM 位置。

C. 参数效率

CSBlock 的额外参数仅来自 CNN 分支和融合层。CNN 分支包含 $2 \times (3^2 \times C^2) = 18C^2$ 参数，融合线性层包含 $2C \times C = 2C^2$ 参数。在 MaIR Light 的配置下（$C = 60$），每个 CSBlock 额外参数量为 $20 \times 60^2 = 72{,}000$，占 RMB 总参数量的约 5.5%。24 个 RMB 块合计新增约 1.73M 参数（MaIR Light 的四层深度为 [6, 6, 6, 6]）。

方案	混合方式	代表模型	PSNR	问题
串行后置	SSM → CNN	MambaIR (CAB)	28.21 dB	SSM 输出已丢失局部信息，CNN 事后补救效率低
纯线性	无 CNN	MaIR (Mlp)	30.01 dB	全局已优，规律纹理上缺局部偏置
层内并行	**SSM ∥ CNN**	**MaIR-CSB (本文)**	**30.27 dB**	**CNN 从原始输入提取局部先验，与 SSM 互补**

4.3 创新效果

MaIR-CSB 在与 MaIR 完全相同的训练配置下完成 25000 次迭代

测试集	MaIR (复现)	**MaIR-CSB (创新)**	MaIR 原文	**Δ (CSB vs MaIR)**	CSB 达成率
Set5	31.64	**31.98**	32.48	**+0.34**	98.5%
Set14	28.22	**28.42**	28.81	**+0.20**	98.6%
B100	27.34	**27.47**	27.71	**+0.13**	99.1%
Urban100	25.29	**25.71**	26.60	**+0.42**	96.7%
平均	28.12	**28.40**	28.90	**+0.27**	97.9%

四基准上 CSB 的增幅形成清晰的纹理梯次：Urban100（+0.42 dB）> Set5（+0.34 dB）> Set14（+0.20 dB）> B100（+0.13 dB），与 4.1 节的理论预测一致。Urban100 的规律性纹理（砖缝、栏杆、斑马线）空间周期恰好落在 3×3 卷积核单次感受野内，CNN 在源头上即可捕获局部周期

性，而纯 Mlp 的每个 token 只能看到自身的通道向量，相邻 token 间的空间关系需通过梯度回传缓慢建立，在数据受限条件下这一先天劣势被放大。B100 的自然随机纹理以不规则多尺度模式为主，核心挑战在全局统计而非局部周期，SSM 已能胜任，CNN 增量最小。Set5（人脸静物）和 Set14（混合场景）居中，符合混合纹理的预期。所有测试集均为正收益，无一退化，验证了并行融合设计的稳健性。

训练收敛方面，CSBlock 在 2500 步时领先 MaIR 0.54 dB，10000 步突破 30 dB（比 MaIR 提前约 12000 步）。随着 SSM 收敛，边际贡献逐步收窄至 0.26 dB 的稳态值，反映了两分支在信息类型上的结构性互补而非临时搀扶。

综合来看，CSBlock 以每块 72K 额外参数（约 5.5% 增量）的轻量代价，在控制变量条件下实现了四基准平均 0.27 dB 的一致提升。增益集中于规律纹理这一纯 SSM 的已知软肋，且在训练早期提供了 2.5 倍的收敛加速。B100 达成率从 98.7% 提升至 99.1%，Urban100 达成率从 95.1% 提升至 96.7%。



依次为LR:18.6db , MaIR:19.9db , MaIR-CSB:20.6db ,GT

5 总结和展望

5.1 总结

本文以图像超分辨率为任务背景，围绕 Mamba/SSM 架构在 2D 视觉应用中的核心挑战展开研究，完成了从问题发现到方案验证再到模型改进的完整闭环。

期中阶段，通过对 MambaIR（ECCV 2024）的复现与消融实验，发现 Cross-Scan 四方向扫描存在 75% 的结构性冗余，根因在于 1D 展平对 2D 空间连续性的破坏。基于此提出了嵌套 S 型扫描（NSS）的理论方案。该方案与 MaIR（CVPR 2025）的核心创新方向一致，形成了问题发现到学界验证的闭环。

期末阶段，首先在严格控制变量的条件下复现了 MaIR。相同数据集（DIV2K）、相同训练量（25K iter）、相同超参数下，MaIR 在四基准上的平均 PSNR 达到 28.12 dB，较 MambaIR 的 26.52 dB 提升 1.61 dB，验证了 NSS 扫描路径相比 Cross-Scan 的显著优势。

在复现基础上，针对 MaIR 以纯线性 Mlp 替代卷积模块后规律纹理残差偏大的问题，提出了 CSBlock。该模块在 VMM 旁路并联轻量 3×3 卷积，以层内并行融合的方式为 SSM 补充局部纹理归纳偏置。改进后的 MaIR-CSB 以每块仅 5.5% 的参数增量，在四基准上实现平均 0.27 dB 的提升，且增益集中于规律纹理数据集（Urban100 +0.42 dB），取得创新结果的量化。

5.2 展望

本文的工作在以下几个方面存在局限，也为后续研究提供了方向。

1) 实验规模有限。所有实验均在 Light 变体、DIV2K 数据集、×4 超分辨率这一单一配置下完成。CSBlock 在更大模型、更多数据（如 DF2K）和其他退化任务（去噪、去模糊）上的泛化性有待验证。
2) CNN 分支的设计依赖经验选择（两层 3×3 卷积、通道拼接融合），更优的结构可能存在于更广的设计空间中。
3) 纹理规律性与 CNN 增益之间的关联目前仅停留在现象层面的描述性分析，缺少量化的纹理复杂度度量来对这一关联进行更精细的建模和预测。

参考文献

[1] Dong C, Loy C C, He K, et al. Image super-resolution using deep convolutional networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 38(2): 295-307.

[2] Liang J, Cao J, Sun G, et al. SwinIR: Image restoration using swin transformer[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 1833-1844.

[3] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[J]. arXiv preprint arXiv:2312.00752, 2023.

[4] Gu A, Dao T, Ermon S, et al. Hippo: Recurrent memory with optimal polynomial projections[C]//Advances in Neural Information Processing Systems (NeurIPS). 2020: 1474-1487.

[5] Gu A, Goel K, Re C. Efficiently modeling long sequences with structured state spaces[C]//International Conference on Learning Representations (ICLR). 2022.

[6] Liu Y, Tian Y, Zhao Y, et al. VMamba: Visual state space model[J]. arXiv preprint arXiv:2401.10166, 2024.

[7] Li B, Zhao H, Wang W, et al. MaIR: A locality- and continuity-preserving mamba for image restoration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2025.

[8] Liu Y, Tian Y, Zhao Y, et al. VMamba: Visual state space model[C]//Advances in Neural Information Processing Systems (NeurIPS). 2024.

[9] Agustsson E, Timofte R. NTIRE 2017 challenge on single image super-resolution: Dataset and study[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). 2017: 126-135.

[10] Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). 2017: 136-144.

[11] Shi W, Caballero J, Huszár F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 1874-1883.

[12] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 5998-6008.

[13] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

[14] Wang X, Xie L, Dong C, et al. Real-ESRGAN: Training real-world blind super-resolution with pure synthetic data[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW). 2021: 1905-1914.

装 订 线